

# Multiple Kernel Learning

qhy

2017 年 8 月 22 日

## 目录

<b>1 Multiple Kernel Learning</b>	<b>2</b>
1.1 核方法原理 . . . . .	2
1.2 Mercer条件 . . . . .	2
1.3 核函数的性质 . . . . .	2
1.4 多核学习 . . . . .	2
1.4.1 组合方式 . . . . .	3
1.4.2 启发式规则 . . . . .	3
1.4.3 贝叶斯方法 . . . . .	4
1.4.4 Boosting 方法?????? . . . . .	4
1.5 多尺度核方法 . . . . .	4
1.5.1 具有多尺度表示能力的核函数 . . . . .	4
1.5.2 多尺度核的学习方法 . . . . .	4

# 1 Multiple Kernel Learning

## 1.1 核方法原理

给定样本  $\mathcal{D} = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}$ , 求从输入  $\mathbf{x}$  到  $y$  的映射。

可以先进行一次非线性映射  $\Phi: \mathbf{x} \rightarrow \phi(\mathbf{x})$ , 把  $\mathbf{x}$  映射到高维空间

然后再在数据新的表示方法  $\mathcal{D}' = \{(\phi(\mathbf{x}_1), y_1), \dots, (\phi(\mathbf{x}_n), y_n)\}$  上考虑原来的机器学习问题。

和函数把非映射和特征空间中的两个向量的内积两步集合起来, 使得非线性映射隐式地进行。具体地说, 使用核函数来进行高维空间的内积计算, 通过对低维空间上的运算来计算高维空间的内积, 而不是直接使用高维空间的表示进行内积, 避免了维数灾难<sup>1</sup>。

## 1.2 Mercer条件

**Mercer条件:** 设  $X$  是  $R^n$  的一个紧子集,  $k: X \times X \rightarrow R$  是一个连续的对称函数, 如果它在希尔伯特空间上的积分算子满足积分正定条件:

$$\forall f \in L_2(X), \int_{X \times X} k(\mathbf{x}, \mathbf{z}) f(\mathbf{x}) f(\mathbf{z}) d\mathbf{x} d\mathbf{z} \quad (1)$$

那么一定存在一个特征空间  $F$  和一个映射  $\Phi: X \rightarrow F$ , 使得

$$k(\mathbf{x}, \mathbf{z}) = \Phi(\mathbf{x}) \times \Phi(\mathbf{z}) \quad (2)$$

## 1.3 核函数的性质

- 容许核<sup>2</sup>的正系数线性组合是容许核。
- 容许核的乘积是容许核。
- 函数乘积的积分是容许核。

## 1.4 多核学习

多核学习: 使用多个核的线性或非线性组合来构造新的核, 然后使用新的核考虑原来的问题。

以简单地线性组合为例:

新的核函数为:

$$\mathbf{K}' = \sum_{i=1}^n \beta_i \mathbf{K}_i \quad (3)$$

那么对于样本  $\mathbf{X}$  和标签  $\mathbf{Y}$  来说, 最小化的问题可以写成以下形式:

$$\min_{\beta, c} E(\mathbf{Y}, \mathbf{K}'c) + R(\mathbf{K}, c) \quad (4)$$

其中,  $E$  是误差函数,  $R$  是正则项。

<sup>1</sup>在高维情形下出现的数据样本稀疏, 距离计算困难等问题, 是所有机器学习方法共同面临的严重障碍, 被称为“维数灾难”(curse of dimensionality)

<sup>2</sup>满足Mercer条件的和函数称为容许核

### 1.4.1 组合方式

多核学习,简单地看,就是多个核的线性和非线性组合(合成出一个新的核),因此,组合的方式是一个重要因素。根据核函数的性质,我们有加和和乘积两个基本方式。

举个例子:

- pairwise kernels

$$k((x_{1i}, x_{1j}), (x_{2i}, x_{2j})) = k(x_{1i}, x_{2i})k(x_{1j}, x_{2j}) + k(x_{1i}, x_{2j})k(x_{1j}, x_{2i}) \quad (5)$$

- 线性组合

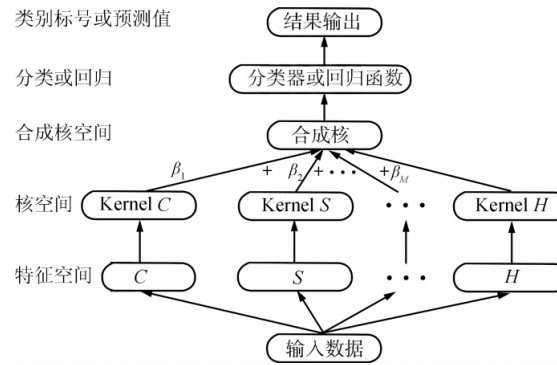


图 1: 多核函数线性组合合成示意图

### 1.4.2 启发式规则

启发式规则:简单地讲,就是给多核增加各种参数,使用学习或者启发式的方法来定义各种参数。

例1:

假设:

- $\pi_m$ 表示只使用第 $m$ 个核函数的情况下的精度
- $\delta$ 表示某个阈值

定义:

$$\beta_m = \frac{\pi_m - \delta}{\sum_{h=1}^n (\pi_h - \delta)} \quad (6)$$

例2

定义相似度:

$$A(\mathbf{K}_1, \mathbf{K}_2) = \frac{\langle \mathbf{K}_1, \mathbf{K}_2 \rangle}{\sqrt{\langle \mathbf{K}_1, \mathbf{K}_1 \rangle \langle \mathbf{K}_2, \mathbf{K}_2 \rangle}} \quad (7)$$

则:

$$\beta_m = \frac{A(\mathbf{K}_m, \mathbf{Y}\mathbf{Y}^T)}{\sum_{h=1}^n A(\mathbf{K}_h, \mathbf{Y}\mathbf{Y}^T)} \quad (8)$$

为什么是 $\mathbf{Y}\mathbf{Y}^t$

### 1.4.3 贝叶斯方法

贝叶斯方法:给需要学习的参数一个先验分布

举个例子:

最终预测函数为:

$$f(\mathbf{x}) = \sum_{i=0}^n \alpha_i \sum_{m=1}^p \eta^m \mathbf{K}_m(\mathbf{x}_i^m, \mathbf{x}^m) \quad (9)$$

假设,  $\eta$  为狄利克雷分布,  $\alpha$  为高斯分布

### 1.4.4 Boosting 方法??????

## 1.5 多尺度核方法

多尺度核方法,使用尺度大的基核函数对平缓变换的样本进行分类,使用尺度小的基和核函数对剧烈变化的样本进行分类。

### 1.5.1 具有多尺度表示能力的核函数

多尺度核方法的基础就是要找一组能具有多尺度表示能力的核函数,在被广泛使用的核函数中,RBF核

$$k(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2\sigma^2}\right) \quad (10)$$

是最受欢迎的。

以此核为例,  $\sigma$  取不同的值表示不同的尺度。  $\sigma$  较大的时,用来对那些平缓变化的样本进行分类,小的时候对剧烈变换的样本进行分类。

$k$  从一定程度上也是描述样本之间的相似度,当  $\sigma$  大的时候,表示相似,因此可以对平缓变化的样本进行分类。

### 1.5.2 多尺度核的学习方法

考虑两个尺度的核  $k_1$  和  $k_2$  的分类问题,我们要合成的决策函数为以下形式:

$$f(\mathbf{x}) = f_1(\mathbf{x}) + f_2(\mathbf{x}) \quad (11)$$

其中,

$$f_1(\mathbf{x}) = \sum_{i=1}^N \alpha_i k_1(\mathbf{x}_i, \mathbf{x}) + b_1 \quad (12)$$

$$f_2(\mathbf{x}) = \sum_{i=1}^N \beta_i k_2(\mathbf{x}_i, \mathbf{x}) + b_1 \quad (13)$$

这里一个尺度的核函数表示一个输出值,最终是值的叠加,而不是前面的核的叠加

这里假设  $k_1$  是大尺度的核,  $k_2$  是小尺度的核。

首先通过大尺度的单核  $k_1$  来构造  $f_1(\mathbf{x})$  来拟合光滑的区域,再在  $f_1 \mathbf{x}$  的基础上,使用尺度较小的核  $k_2$  构造  $f_2 \mathbf{x}$ , 这样  $f_1(\mathbf{x}) + f_2 \mathbf{x}$  比  $f_1 \mathbf{x}$  具有更好的拟合性能。