

# ML Note

qhy

2017 年 7 月 31 日

## 目录

<b>1</b>	<b>SVM</b>	<b>2</b>
1.1	线性SVM . . . . .	3
1.2	线性SVM2 . . . . .	3

# 1 SVM

定义标签: $\hat{y} = \{+1, -1\}$ , +1表示正类, -1表示负类定义输出:

$$g(x) = \begin{cases} +1 & , f(x) > 0 \\ -1 & , f(x) < 0 \end{cases} \quad (1)$$


定义loss function:

$$L(f) = \sum_n I(g(x^n) \neq \hat{y}^n) \quad (2)$$

也就是统计分类错误的个数,从更一般的角度来看,就是每分类错误一个,就给一定的惩罚

分析: $\hat{y}^n f(x^n) > 0$ 的时候,分类正确,无论是正类还是负类,

如果把这个看做一个新的变量 $t$ ,那么损失函数(一个数据的损失函数)就可以定义成 $t > 0$ 时无惩罚, $t < 0$ 的时候给出一定的惩罚。



理想的情况就是图1中的黑线,分类错误就给出惩罚。

由于此loss function使用梯度下降算法麻烦,故使用一个惩罚函数 $l$ 代替 $I$ :

$$L(f) = \sum_n I(f(x^n), \hat{y}^n) \quad (3)$$

红色线为**Square loss**:

$$l(f(x^n), \hat{y}^n) = (\hat{y}^n f(x^n) - 1)^2 \quad (4)$$

显然是不合理的,因为它对于分类正确的结果也给出了惩罚。

蓝色线为**sigmoid + square loss**:

$$l(f(x^n), \hat{y}^n) = (\sigma(\hat{y}^n f(x^n)) - 1)^2 \quad (5)$$

这样,得到的结果是合理的,对于分类正确,确定性高的给出低惩罚,对于分类错误,甚至错误的离谱的,则给出大的惩罚

但是有一个问题就是,对于分类错误的结果,它的惩罚很低。

绿色线为**Sigmoid + cross entropy**

$$l(f(x^n), \hat{y}^n) = \ln(1 + \exp(-\hat{y}^n f(x^n))) \quad (6)$$

蓝色线为**hinge loss**:

$$l(f(x^n), \hat{y}^n) = \max(0, 1 - \hat{y}^n f(x^n)) \quad (7)$$

对于分类正确的结果,只要 $\hat{y}^n f(x^n) < 1$ 的数据还是会给出惩罚,而SVM采用的就是HingeLoss从 $f(x)$ 来看, $f(x)$ 为分界线,只要在 $f(x)$ 上下距离为1的样本都会给出惩罚。

## 1.1 线性SVM

模型如下:

- Step 1: Function (Model)

$$f(x) = \sum_i w_i x_i + b = \begin{matrix} \text{New } w \\ \begin{bmatrix} w \\ b \end{bmatrix} \end{matrix} \cdot \begin{matrix} \text{New } x \\ \begin{bmatrix} x \\ 1 \end{bmatrix} \end{matrix} = w^T x$$

- Step 2: Loss function

$$L(f) = \sum_n l(f(x^n), \hat{y}^n) + \lambda \|w\|_2$$

*convex* (pointing to the loss function curve)

$$l(f(x^n), \hat{y}^n) = \max(0, 1 - \hat{y}^n f(x^n))$$

梯度下降:

$$\frac{\partial L(f)}{\partial w_i} = \sum_n \frac{-\delta(\hat{y}^n f(x^n) < 1) \hat{y}^n x_i}{c^n(w)} \quad w_i \leftarrow w_i - \eta \sum_n c^n(w) x_i^n$$

## 1.2 线性SVM2

至此,线性SVM结束,但是这个SVM和之前见到的SVM貌似不太一样?对偶问题,SMO,等等这些东东呢?

另一种描述:

Minimizing loss function L:

$$L(f) = \sum_n \epsilon^n + \lambda \|w\|_2$$

$$\epsilon^n = \max(0, 1 - \hat{y}^n f(x^n))$$

$\epsilon^n$ : slack variable  
Quadratic programming problem

$$\epsilon^n \geq 0$$

$$\epsilon^n \geq 1 - \hat{y}^n f(x^n) \Rightarrow \hat{y}^n f(x^n) \geq 1 - \epsilon^n$$

经过这样处理,原问题从最小化:

$$L(f) = \sum_n l(f(x^n), \hat{y}^n) + \lambda \|w\|_2$$

变成了最小化:

$$L(f) = \sum_n \epsilon^n + \lambda \|w\|_2 \quad \text{s.t.} \quad \hat{y}^n f(x^n) \geq 1 - \epsilon^n$$

进一步处理,问题变成最小化:

$$L(f) = \lambda \|w\|_2 \quad \text{s.t.} \quad \hat{y}^n f(x^n) \geq 1$$